

SAÉ1.01 IMPLÉMENTATION

Dépendant aux réseaux sociaux?

À lire avant de commencer

Cette SAÉ est à effectuer de manière **individuelle**. L'utilisation d'IA génératives est fortement déconseillée, si vous y avez recours vous devez l'utiliser exclusivement pour apprendre et non pour faire à votre place.

- tout partage de code entre deux étudiants sera sanctionné par un zéro pour les deux étudiants concernés
- tout étudiant faisant passer pour son travail un contenu (même mineur) généré par une IA sera sanctionné par un zéro

la commission disciplinaire de l'université d'Orléans sera saisie dans ces deux cas.

1 Introduction

Le but de cette SAE est de travailler la **Compétence 1** : *Développer des applications informatiques simples* dans le cadre des **apprentissages critiques** :

- **AC1** *Implémenter des conceptions simples*
- **AC3** *Faire des essais et évaluer leurs résultats en regard des spécifications*

dont les **composantes essentielles** sont :

- ✓ en précisant et en respectant les besoins décrits par le client
- ✓ en veillant à la qualité du code et à sa documentation

Votre note finale à cette SAÉ comporte trois composantes :

1. la qualité de votre livrable : codes python et rapport
2. les compétences que vous aurez développées durant cette SAÉ : évaluation sur feuille
3. votre démarche de gestion de projet : progression régulière sur les 4 semaines et gestion de votre dépôt Git

Les détails des rendus ainsi que les consignes de gestion de votre dépôt Git vous sont donnés à la fin de ce document.

2 Le Sujet

Votre client : une équipe de chercheurs en sciences de l'éducation. Elle s'intéresse aux liens entre l'usage des réseaux sociaux, le sommeil et le bien-être des étudiants. Pour cela elle a collecté, auprès de 705 étudiants de 110 pays différents, des informations sur leurs pratiques numériques. Elle vous demande d'implémenter un certain nombre de fonctions permettant d'exploiter ces données, puis d'aller plus loin en **prédisant** le niveau d'addiction d'un étudiant à partir de son profil d'usage.

D'où viennent ces données ?

Ces données n'ont pas été inventées pour l'exercice : elles sont issues d'une véritable enquête, menée par questionnaire auto-administré diffusé par voie électronique auprès d'étudiants de plusieurs pays, et publiée en accès libre. Les réponses sont anonymes et *déclaratives* : chaque étudiant évalue lui-même son temps d'écran, sa santé mentale et son addiction. C'est une limite à garder en tête au moment d'interpréter vos résultats.

Référence : W. Badawy, *Survey Dataset on Students' Social Media Usage, Addiction Severity, Sleep, Mental Well-Being, and Academic Impact*, IEEE DataPort, 2026, doi.org/10.21227/kx3c-1043. Le même jeu de données est diffusé sur Kaggle sous le titre *Students' Social Media Addiction*.

Les fichiers `ssma1.csv`, `ssma2.csv` et `ssma3.csv` en sont un extrait remis en forme pour cette SAÉ : colonnes traduites et réordonnées, et répartition en deux sources partielles qui se recouvrent.

Ces informations sont disponibles sous la forme d'un fichier CSV. Lorsque le fichier est chargé en mémoire, on obtient une liste de tuples, chaque tuple modélisant le *profil* d'un étudiant.

Chaque profil est représenté par un tuple contenant 7 composants :

0. `identifiant` : un entier indiquant le numéro d'anonymat de l'étudiant
1. `pays` : une chaîne de caractères indiquant le pays de l'étudiant
2. `plateforme` : une chaîne de caractères indiquant le réseau social qu'il utilise le plus
3. `heures_ecran` : un flottant indiquant son temps d'écran moyen par jour, en heures
4. `heures_sommeil` : un flottant indiquant son temps de sommeil moyen par nuit, en heures
5. `sante_mentale` : un entier de 1 (mauvais) à 10 (excellent) évaluant sa santé mentale
6. `score_addiction` : un entier de 1 (faible) à 10 (fort) évaluant son addiction aux réseaux sociaux

Par exemple, l'étudiant n°11, qui habite en France, utilise principalement Snapchat, passe en moyenne 4.8 heures par jour devant un écran, dort 6.2 heures par nuit, évalue sa santé mentale à 5/10 et obtient un score d'addiction de 7/10. Son profil est représenté par le tuple suivant :

```
(11, 'France', 'Snapchat', 4.8, 6.2, 5, 7)
```

Une liste de profils est donc simplement une liste de tuples décrits ci-dessus. On considère qu'un étudiant est **dépendant** aux réseaux sociaux lorsque son score d'addiction atteint 7.

Attention : toutes les listes de profils sont des listes sans doublons, triées par ordre alphabétique de pays, puis par ordre croissant d'identifiant.

Deux étudiants d'un même pays ont toujours des identifiants différents, mais **un même identifiant peut être attribué à des étudiants de pays différents** : c'est donc le couple (pays, identifiant) qui désigne un étudiant, et jamais l'identifiant seul. Le fichier qui vous est fourni ne contient pas un tel cas, mais vos fonctions doivent le traiter correctement : pensez à le tester.

Dans le fichier `explore_ssma.py` vous trouverez la documentation de la série de fonctions à implémenter pour cette SAÉ. Dans le fichier `test_explore_ssma.py` vous trouverez des exemples de profils et de listes de profils, ainsi que, pour chaque fonction, un test qui ne comporte que deux cas. Ces tests sont un point de départ, en aucun cas un travail terminé : vous devez impérativement

les compléter pour TOUTES les fonctions. Pensez en particulier aux listes vides, aux recherches infructueuses et aux identifiants portés par des étudiants de pays différents.

Le fichier `ssma1.csv` contient l'ensemble des profils collectés. Les fichiers `ssma2.csv` et `ssma3.csv` illustrent le fait que ces informations peuvent venir de plusieurs sources différentes : certains étudiants ont répondu aux deux enquêtes. Si on veut rassembler ces deux sources en évitant les doublons, nous avons besoin de la fonction `fusionner_profils`.

3 Prédire avec les k plus proches voisins

La dernière série de fonctions à implémenter va vous permettre de mettre en œuvre un véritable algorithme d'intelligence artificielle : l'algorithme des **k plus proches voisins** (*k nearest neighbours*). Son principe est très simple : *pour deviner une information manquante sur un nouvel individu, on regarde les individus qui lui ressemblent le plus.*


Pour cela il faut d'abord être capable de mesurer à quel point deux profils se ressemblent. On utilise une **distance** : plus elle est petite, plus les deux étudiants ont des habitudes proches. Ici, la distance entre deux profils est calculée à partir de trois critères (le temps d'écran, le temps de sommeil et le score de santé mentale) selon la formule :

$$d(p_1, p_2) = \sqrt{(\text{ecran}_1 - \text{ecran}_2)^2 + (\text{sommeil}_1 - \text{sommeil}_2)^2 + (\text{sante}_1 - \text{sante}_2)^2}$$

Une fois cette distance définie, l'algorithme se déroule en trois temps. Pour un nouvel étudiant dont on ne connaît pas le score d'addiction :

1. on calcule la distance entre son profil et *chacun* des profils déjà connus,
2. on ne retient que les k profils les plus proches (ses *k voisins*),
3. on en déduit une prédiction : soit la **moyenne** des scores d'addiction de ses voisins, soit, pour répondre par oui ou par non, un **vote majoritaire** (est-il dépendant?).

La figure ci-dessous illustre le principe avec $k = 5$ et seulement deux critères (pour pouvoir dessiner). Parmi les 5 voisins les plus proches du nouvel étudiant ($\star$), 3 sont dépendants et 2 ne le sont pas : le vote majoritaire prédit donc que ce nouvel étudiant est dépendant.



Pour construire la liste des k voisins les plus proches sans avoir à trier toute la liste des profils, vous implémenterez la fonction `insérer_voisin` qui insère un voisin à sa place dans une liste déjà triée par distance croissante, en ne conservant que les k meilleurs. Il suffit alors de parcourir une seule fois la liste des profils.

4 Quelques questions de votre client

Grâce à vos fonctions et au fichier `ssma1.csv`, vous permettrez à votre client de répondre à des questions telles que :

- Quelle proportion des étudiants interrogés est dépendante aux réseaux sociaux ?
- Quels sont les réseaux sociaux représentés dans l'enquête ? Lequel est le plus utilisé ?
- Quel est le profil de l'étudiant le plus dépendant ?
- Combien d'étudiants passent plus de 6 heures par jour devant un écran ? Quelle proportion d'entre eux est dépendante ?
- Quel est le temps d'écran quotidien moyen des étudiants qui utilisent principalement TikTok ? Et de ceux qui utilisent principalement LinkedIn ?
- Un nouvel étudiant passe 6 heures par jour sur les réseaux, dort 5 heures par nuit et évalue sa santé mentale à 4/10 : est-il probablement dépendant ? Quel score d'addiction peut-on lui prédire ?

En revanche, les fonctions proposées peuvent être insuffisantes pour répondre directement à d'autres questions plus avancées telles que :

- Les étudiants qui dorment le moins sont-ils réellement les plus dépendants ?
- Dans quels pays les étudiants sont-ils les plus dépendants ?
- **Vos prédictions sont-elles fiables ?** Vous pouvez le vérifier : prenez un étudiant du fichier dont vous connaissez déjà le score d'addiction, faites comme si vous ne le connaissiez pas, prédisez-le à partir des *autres* étudiants, puis comparez avec la vraie valeur. En recommençant sur de nombreux étudiants, vous saurez à quel point votre prédiction est bonne.
- Quelle valeur de k donne les meilleures prédictions ?

Il vous revient de proposer de nouvelles fonctions de traitement afin d'anticiper d'autres besoins de votre client.

5 Travail à faire

5.1 Dépôt GitHub (à réaliser dès la première semaine)

- Créer un dépôt privé GitHub dédié à cette SAÉ,
- Ajouter le collaborateur GCleuziou à votre dépôt (*Settings*→*Collaborators*→*Add people*),
- Renseigner l'url de votre dépôt dans l'activité "URL dépôt Git SAE Python" prévue à cet effet dans le cours Célène (toute modification d'url *a posteriori* devra rester exceptionnelle et nécessitera d'en faire la demande à l'enseignant responsable).
- Votre dépôt GitHub devra être maintenu à jour en permanence durant toute la durée de la SAÉ (a minima un commit après chaque séance hebdomadaire dédiée à cette SAÉ)

5.2 Développement

- Implémenter les fonctions du fichier `explore_ssma.py` et y ajouter vos propres fonctions.
- Compléter le fichier `test_explore_ssma.py` et y ajouter les fonctions de test pour vos propres fonctions.
- Compléter le fichier `consultation_ssma.py` qui permet de consulter et de manipuler les données chargées à partir d'un fichier CSV. Un exemple (trop) basique d'interaction vous est donné ci-dessous. Faites preuve de créativité! 💡

```
Temps d'écran moyen par jour (en heures)? 6
Temps de sommeil moyen par nuit (en heures)? 5
Score de santé mentale (de 1 à 10)? 4
Les 5 étudiants au profil le plus proche ont un score d'addiction de 8, 8, 9, 8 et 9.
Score d'addiction prédit : 8.4/10 : cet étudiant est probablement dépendant.
```

6 Travail à rendre

Rendu : le **8 novembre** vous devrez avoir effectué deux rendus sur CELENE :

- une archive .zip contenant :
 - le fichier `explore_ssma.py` complété,
 - le fichier `test_explore_ssma.py` complété,
 - le fichier `consultation_ssma.py` complété,
- un fichier `compte-rendu.pdf` contenant une analyse synthétique et personnelle de votre travail. Ce document doit vous permettre de démontrer que vous avez acquis les compétences concernées par la SAÉ. Il fera une à deux pages (3500 signes espaces compris maximum) et contiendra vos prénom, nom et groupe ainsi qu'une analyse de votre travail :
 - Synthèse : Qu'avez-vous réussi à faire ? Qu'est-ce qui n'a pas été fait ? Quelles fonctions ou fonctionnalités de votre invention avez-vous ajoutées ?
 - Analyse : quelles difficultés avez-vous rencontrées et comment les avez-vous surmontées ? Quelles nouvelles notions (non vues en Cours/TD/TP) avez-vous vues pendant ce projet ?
 - Démonstration de compétence : donnez un exemple permettant de montrer la manière dont vous avez mis en œuvre la compétence ciblée par la SAÉ, en vous appuyant sur les apprentissages critiques et composantes essentielles impliqués (voir introduction).